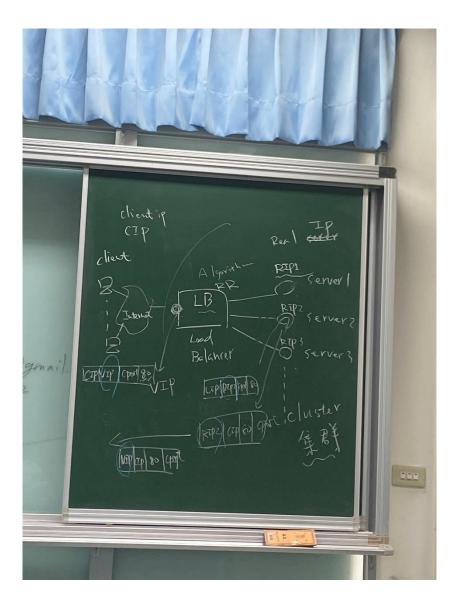
0625 Load Balancer 使用 p4 實作負載均衡器

我們現在所使用的網頁伺服器,一台機器如果性能比較好的,大概能服務一兩 萬條連線,如果人數再更多,就沒有辦法負荷。所以,通常這種網頁伺服器都 是用集群式的方式在服務,也就是說,它會開很多台,同時很多台在等待把使 用者的請求服務分散掉,因為像一些購物節或者是搶票,使用者請求會非常 多,幾台機器可能沒辦法應付,所以就會有很多台機器。

Connection hash

當很多的客戶,如果集中在一台,容易爆掉,所以負載均衡就是把客戶的請求平均分散到不同伺服器上,這樣的話每一台伺服器的壓力就比較小,反應時間快,如果全都集中在單一台就會來不及服務,就會產生佇列,瀏覽器畫面就會在那邊等待,所以我們希望,當一鍵按下去可以快速得到我想要的東西。



因為這些伺服器每台都會有一個 ip,這些伺服器的 ip 叫做 real ip (rip),這個負載均衡器會有一個對外 ip,叫做 virtual ip (vip)。

為什麼要有 vip?

因為當使用者要連線的時候,他們不會去記每一台的 ip 位址,所以就固定一個固定的 ip,他們只要連到這個 ip,就由它幫忙做分配。ex:選課系統客戶的 ip 叫做 client ip (cip)。

負載均衡器的概念就是,它會提供一個固定 ip,只要連線連進來這個固定 ip,它會自動幫你進行分發的動作。

只要來源相同,雜湊值就相同,如果來源不同,雜湊值相同的機率很小很小,如果真的相同,這種情況就稱為碰撞,那麼這個雜湊函數就不是很好。

p4-14 寫法轉換成 p4-16

執行步驟:

- 1. 打開終端機,切到 p4-test 資料夾
- 2. 建立資料夾(mkdir hash-lb),並切到 hash-lb 資料夾
- 3. gedit hash-lb.p4 &,去 http://csie.nqu.edu.tw/smallko/sdn/LBP4.htm 把 load_balance.p4 複製並貼上
- 4. 在終端機輸入指令 p4c-bm2-ss -p4v 14 -pp hash-lb16.p4 hash-lb.p4
- 5. gedit hash-lb16.p4 & 就把 p4-14 寫法轉換成 p4-16 了 p4-14 轉 p4-16 網站: https://p4tw.org/%E5%B0%87-p4-14- %E5%BF%AB%E9%80%9F%E8%BD%89%E6%8F%9B%E8%87%B3-p4-16- %E6%96%B9%E6%B3%95/

負載均衡器

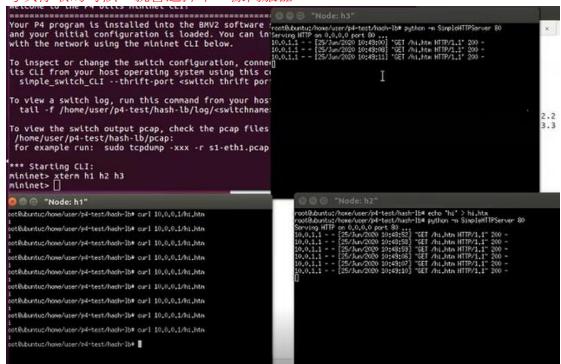
[Topology]

```
H1 (10.0.1.1) -----(P4 switch: load balancer) ------ H2 (Simple HTTP Server, 10.0.2.2)+
------ H3 (Simple HTTP Server, 10.0.3.3)+
Virtual IP: 10.0.0.1+
```

第一個實驗:

- 1. 打開終端機,切到 p4-test/hash-lb 資料夾
- 2. gedit commands.txt & ,一樣去 LBP4.htm 網站把 s1-command.txt 複製並貼上
- 3. gedit p4app.json &,把 p4app.json 貼上
- 4. 在終端機執行 p4run,開啟三個終端 xterm h1 h2 h3
- 5. 在 h3 執行 python -m SimpleHTTPServer 80
- 6. 在 h2 執行 echo "hi" > hi.htm 產生一個簡單的網頁,再執行 python -m SimpleHTTPServer 80
- 7. 在 h1 執行 curl 10.0.0.1/hi.htm

每次存取的時候,就會選擇不一樣伺服器



量測效能指標的工具: apachebench

https://blog.miniasp.com/post/2008/06/30/Using-ApacheBench-ab-to-to-Web-stress-test

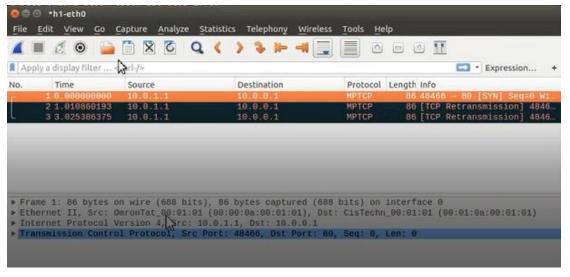
第二個實驗

先安裝 ab: apt install apache2-utils

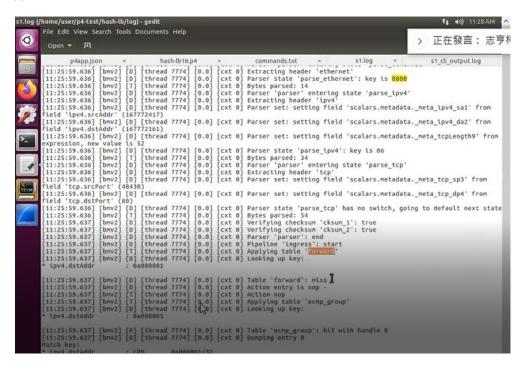
- 1. 在剛剛的 h1 輸入 ab -n 1000 -c 10 http://10.0.0.1/hi.htm
- 2. h2,h3 就會跑,h1 就會顯示 100,200 次的時間,最後做完會告訴你總共花了多久
- 3. 接下來測試 4 台機器,先去 p4app.json,s1-commands.txt 改 規則
- 4. 再執行一次 p4run, xterm h1 h2 h3 h4 h5
- 5. h2,3,4,5 把伺服器都打開 python -m SimpleHTTPServer 80
- 6. 在 h1 執行 curl 10.0.0.1/hi.htm

模擬同時最多十條連線,總共要有一千次存取,看看需要花多少時間

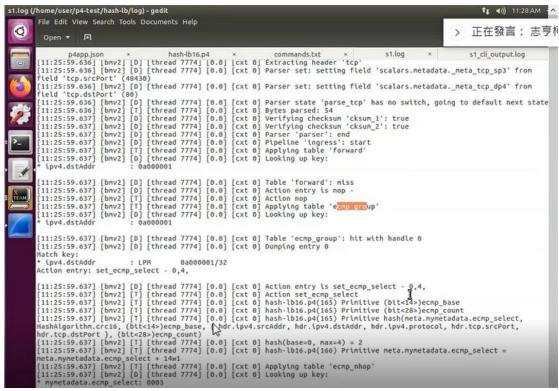
若是失敗,可以再開一個h1,打開 wireshark,選擇h1-etho 並點左上角鯊 魚鰭啟動,然後在h1 執行 curl 10.0.0.1/hi.htm,下面是問題畫面



接著可以到 log 資料夾(open/otherdocuments)把 s1.log,s1_cli_output.log 打開在 s1.log 用 search/find 輸入 0800,因為這是第一個 ip 封包,所以從這邊開始查



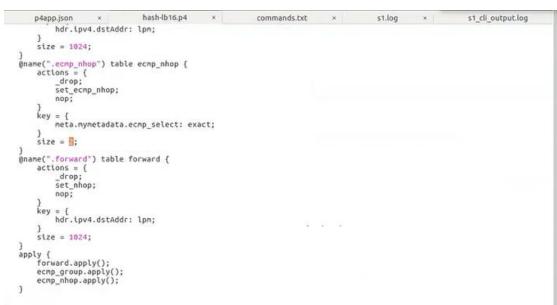
*Forward table 是反向的時候才會用到,所以第一個基本上不會用到就是 miss



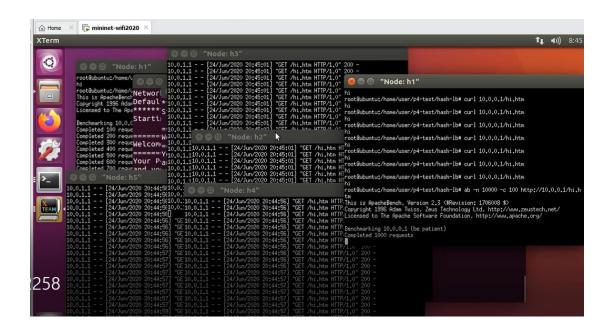
*第二個使用 hash function 去挑 1,2,3,4 裡面的值出來看看挑到什麼值,所以 是 hit ,所以它就會去挑 0~4 裡面的值,結果它挑 2 ,規則上要+1 就變成 3

加完以後,基本上 select 是 3 ,但下一個的 egress_port 是 0000 ,而且是 miss ,這是問題所在!

原因是:剛開始設定的時候,這個表格只能記錄兩筆記錄,但我在 commands 裡面寫了四筆,也就是說,前面兩筆是有用的,後面兩筆是無用 的,會導致後面這兩筆加不進去,所以只要把2 改成 1024(調大一點)就行



- 7. 解決之後,重複上面 4~6 步驟,不斷在 h1 執行 curl 10.0.0.1/hi.htm
- 8. 發現幾乎都是在 h4 & h5 跑,所以改用 ab -n 1000 -c 10 http://10.0.0.1/hi.htm 跑看看,但還是一樣
- 9. 只要把 1000 改 10000, 10 改成 100, 就可以成功了



s1-commands.txt

```
table_set_default forward nop
table_set_default ecmp_group nop
table_set_default ecmp_nhop nop
table_set_default send_frame nop
table_add forward set_nhop 10.0.1.1/32 => 00:00:0a:00:01:01 1
table_add forward set_nhop 10.0.2.2/32 => 00:00:0a:00:02:02 2
table_add forward set_nhop 10.0.3.3/32 => 00:00:0a:00:03:03 3
table_add ecmp_group set_ecmp_select 10.0.0.1/32 => 0 2(2 改成 4)
table_add ecmp_nhop set_ecmp_nhop 1 => 00:00:0a:00:02:02 10.0.2.2 2
table_add ecmp_nhop set_ecmp_nhop 2 => 00:00:0a:00:03:03 10.0.3.3 3
table_add ecmp_nhop set_ecmp_nhop 3 => 00:00:0a:00:03:04 10.0.4.4 4
table_add ecmp_nhop set_ecmp_nhop 4 => 00:00:0a:00:03:05 10.0.5.5 5
table_add send_frame rewrite_sip 1 => 10.0.0.1
```

如果目的地是 10.0.0.1(vip 位址),就用 hash 去挑,2 代表有兩個選擇,一個是 1 一個是 2。如果定義 hash 的結果是 1(bit),代表要把請求丟給 伺服器 2,如果 hash 值是 2 就丟到伺服器 3(第二台) 0 代表 base 值是 0,hash 從 0 開始(參照 load_balance.p4)

當封包回去的時候,要把原本的來源 ip 轉換成 vip(原本是 rip2, 跑回來變 vip 如黑板圖)

p4app.json

```
{
 "program": "hash-lb16.p4",
 "switch": "simple switch",
 "compiler": "p4c",
 "options": "--target bmv2 --arch v1model --std p4-16",
"switch_cli": "simple_switch_CLI",
 "cli": true,
 "pcap_dump": true,
 "enable log": true,
 "topo module": {
  "file path": "",
  "module name": "p4utils.mininetlib.apptopo",
  "object name": "AppTopo"
 },
 "controller module": null,
 "topodb module": {
  "file_path": "",
  "module_name": "p4utils.utils.topology",
  "object_name": "Topology"
},
 "mininet module": {
  "file path": "",
  "module_name": "p4utils.mininetlib.p4net",
  "object name": "P4Mininet"
},
 "topology": {
  "assignment strategy": "manual",
  "default bw":10,
  "default delay": "1ms",
  "auto gw arp": true,
  "links": [["h1", "s1"], ["s1", "h2"], ["s1", "h3"],["s1", "h4"],["s1", "h5"]],
  "hosts": {
   "h1": {
    "ip": "10.0.1.1",
    "gw":"10.0.1.254"
   },
```

```
"h2": {
   "ip" : "10.0.2.2",
   "gw":"10.0.2.254"
  },
  "h3": {
   "ip": "10. 0.3.3",
   "gw":"10.0.3.254"
   "h4": {
   "ip": "10. 0.4.4",
   "gw":"10.0.4.254"
   "h5": {
   "ip": "10. 0.5.5",
   "gw":"10.0.5.254"
 },
 "switches": {
  "s1": {
   "cli_input":"commands.txt",
   "program": "hash-lb16.p4"
  }
 }
}
```

}

Load_balance.p4

```
#include <core.p4>
#include <v1model.p4>
struct meta t {
    bit<1> do_forward;
    bit<32> ipv4_sa;
    bit<32> ipv4 da;
    bit<16> tcp_sp;
    bit<16> tcp_dp;
    bit<32> nhop ipv4;
    bit<32> if_ipv4_addr;
    bit<48> if_mac_addr;
    bit<1> is_ext_if;
    bit<16> tcpLength;
    bit<8> if index;
}
//在資料處理的過程當中,如果有一些比較重要的東西,可以放到 metadata 裡
struct mymetadata_t {
    bit<14> ecmp select;
}
header arp_t {
    bit<16> htype;
    bit<16> ptype;
    bit<8> hlen;
    bit<8> plen;
    bit<16> opcode;
    bit<48> hwSrcAddr;
    bit<32> protoSrcAddr;
    bit<48> hwDstAddr;
    bit<32> protoDstAddr;
}
header ethernet t {
    bit<48> dstAddr;
```

```
bit<48> srcAddr;
    bit<16> etherType;
}
header ipv4_t {
    bit<4> version;
    bit<4> ihl;
    bit<8> diffserv;
    bit<16> totalLen;
    bit<16> identification;
    bit<3> flags;
    bit<13> fragOffset;
    bit<8> ttl;
    bit<8> protocol;
    bit<16> hdrChecksum;
    bit<32> srcAddr;
    bit<32> dstAddr;
}
header tcp_t {
    bit<16> srcPort;
    bit<16> dstPort;
    bit<32> seqNo;
    bit<32> ackNo;
    bit<4> dataOffset;
    bit<4> res;
    bit<8> flags;
    bit<16> window;
    bit<16> checksum;
    bit<16> urgentPtr;
}
header udp_t {
    bit<16> srcPort;
    bit<16> dstPort;
    bit<16> length_;
    bit<16> checksum;
}
```

```
struct metadata {
    @name(".meta")
    meta_t
                   meta;
    @name(".mymetadata")
    mymetadata t mymetadata;
}
struct headers {
    @name(".arp")
    arp t
                arp;
    @name(".ethernet")
    ethernet_t ethernet;
    @name(".ipv4")
    ipv4 t
                ipv4;
    @name(".tcp")
    tcp_t
    @name(".udp")
    udp_t
                 udp;
}
parser ParserImpl(packet_in packet, out headers hdr, inout metadata meta, inout
standard metadata t standard metadata) {
    @name(".parse_arp") state parse_arp {
         packet.extract(hdr.arp);
         transition accept;
    }
    @name(".parse_ethernet") state parse_ethernet {
         packet.extract(hdr.ethernet);
         transition select(hdr.ethernet.etherType) {
              16w0x800: parse ipv4;
              16w0x806: parse arp;
              default: accept;
         }
    }
    @name(".parse_ipv4") state parse_ipv4 {
         packet.extract(hdr.ipv4);
         meta.meta.ipv4_sa = hdr.ipv4.srcAddr;
```

```
meta.meta.ipv4_da = hdr.ipv4.dstAddr;
         meta.meta.tcpLength = hdr.ipv4.totalLen - 16w20;
         transition select(hdr.ipv4.protocol) {
              8w6: parse_tcp;
              8w17: parse_udp;
              default: accept;
         }
    }
    @name(".parse tcp") state parse tcp {
         packet.extract(hdr.tcp);
         meta.meta.tcp sp = hdr.tcp.srcPort;
         meta.meta.tcp dp = hdr.tcp.dstPort;
         transition accept;
    }
    @name(".parse_udp") state parse_udp {
         packet.extract(hdr.udp);
         transition accept;
    }
    @name(".start") state start {
         meta.meta.if_index = (bit<8>)standard_metadata.ingress_port;
         transition parse_ethernet;
    }
}
control egress(inout headers hdr, inout metadata meta, inout standard_metadata_t
standard metadata) {
    @name("._drop") action _drop() {
         mark to drop(standard metadata);
    }
    @name(".rewrite_sip") action rewrite_sip(bit<32> sip) {
         hdr.ipv4.srcAddr = sip; //如果 sip 是 1(參照 commands.txt)出口是 1
    }
    @name(".nop") action nop() {
    }
    @name(".send_frame") table send_frame {
         actions = {
              drop;
              rewrite_sip;
```

```
nop;
       }
       key = {
           standard_metadata.egress_port: exact;
//如果出口是 1,也就是要離開 load balancer,離開的方向是 1,就要把來源 ip
改成 10.0.0.1(vip)
       }
       size = 256;
   }
   apply {
       send frame.apply();
   }
}
control ingress(inout headers hdr, inout metadata meta, inout standard metadata t
standard metadata) {
   @name(". drop") action drop() {
       mark to drop(standard metadata);
   }
   @name(".set ecmp select") action set ecmp select(bit<8> ecmp base, bit<8>
ecmp count) {
       //這個地方要來做 hash
       //count 值選完以後,hash 完的值放在這(meta.....select)
       hash(meta.mymetadata.ecmp_select, HashAlgorithm.crc16,//演算法
(bit<14>)ecmp_base,//hash 的值的基準點從哪裡開始(預設值 0,base=0,參照
commands.txt)
//hash 五個欄位:來源 ip,目的 ip,通訊協定,來源埠號,目的埠號
{ hdr.ipv4.srcAddr, hdr.ipv4.dstAddr, hdr.ipv4.protocol, hdr.tcp.srcPort,
hdr.tcp.dstPort }, (bit<28>)ecmp_count);//最多挑選挑的上限,從 0 開始挑到
count-1, 出來的值最多是多少(2就是選擇 0 & 1, 3 就是 0,1,2)
meta.mymetadata.ecmp select = meta.mymetadata.ecmp select + 14w1;
//我們挑出來的值雖然是從0&1,但我希望它的值可以再+1,變成1&2
   }
   @name(".nop") action nop() {
   @name(".set ecmp nhop") action set ecmp nhop(bit<48> nhop mac, bit<32>
nhop ipv4, bit<9> port) {
       standard metadata.egress spec = port;
```

```
hdr.ipv4.dstAddr = nhop_ipv4;
    hdr.ethernet.dstAddr = nhop_mac;
    hdr.ipv4.ttl = hdr.ipv4.ttl - 8w1;
}
@name(".set_nhop") action set_nhop(bit<48> dmac, bit<9> port) {
    standard metadata.egress spec = port;
    hdr.ethernet.dstAddr = dmac;
    hdr.ipv4.ttl = hdr.ipv4.ttl - 8w1;
}
@name(".ecmp_group") table ecmp_group {
    actions = {
         drop;
         set_ecmp_select;
         nop;
    }
    key = {
         hdr.ipv4.dstAddr: lpm;
    }
    size = 1024;
}
@name(".ecmp_nhop") table ecmp_nhop {
    actions = {
         drop;
         set_ecmp_nhop;
         nop;
    }
    key = {
         meta.mymetadata.ecmp_select: exact;
    }
    size = 1024;
}
@name(".forward") table forward {
    actions = {
         _drop;
         set_nhop;
         nop;
    key = {
```

```
hdr.ipv4.dstAddr: lpm;
         }
         size = 1024;
    }
    apply {
                                   Ingress 的部分有三個 table:
         forward.apply();
                                   forward.apply(); : table add forward set nhop 10.0.1.1/32 =>
         ecmp_group.apply();
                                   00:00:0a:00:01:01 1
         ecmp nhop.apply();
                                   ecmp_group.apply(); :
    }
                                   table add ecmp group set ecmp select 10.0.0.1/32 => 0 2
}
                                   如果他選擇 vip,就 set_ecmp_select;
                                   ecmp_nhop.apply();
control
                                   根據 select 值,去挑選伺服器
DeparserImpl(packet out
packet, in headers hdr) {
    apply {
         packet.emit(hdr.ethernet);
         packet.emit(hdr.arp);
         packet.emit(hdr.ipv4);
         packet.emit(hdr.udp);
         packet.emit(hdr.tcp);
    }
}
control verifyChecksum(inout headers hdr, inout metadata meta) {
    apply {
         verify checksum(true, { hdr.ipv4.version, hdr.ipv4.ihl, hdr.ipv4.diffserv,
hdr.ipv4.totalLen, hdr.ipv4.identification, hdr.ipv4.flags, hdr.ipv4.fragOffset,
hdr.ipv4.ttl, hdr.ipv4.protocol, hdr.ipv4.srcAddr, hdr.ipv4.dstAddr },
hdr.ipv4.hdrChecksum, HashAlgorithm.csum16);
         verify checksum with payload(true, { hdr.ipv4.srcAddr, hdr.ipv4.dstAddr,
8w0, hdr.ipv4.protocol, meta.meta.tcpLength, hdr.tcp.srcPort, hdr.tcp.dstPort,
hdr.tcp.seqNo, hdr.tcp.ackNo, hdr.tcp.dataOffset, hdr.tcp.res, hdr.tcp.flags,
hdr.tcp.window, hdr.tcp.urgentPtr }, hdr.tcp.checksum, HashAlgorithm.csum16);
    }
}
control computeChecksum(inout headers hdr, inout metadata meta) {
    apply {
```